Victor

VLA 后训练 / 模型量化与推理部署

15381931200 | victorzhiyin@163.com | 上海 | 个人主页：vvviiiccc2001.github.io

职业概述：聚焦具身智能模型后训练、推理优化与机器人实机交付；围绕 π0.5 开展跨机型数据适配、Mid-training 与 Post-training 微调及实机评测 benchmark 搭建，面向 Jetson Orin / Thor 建设自动化量化产线及统一推理框架，覆盖全身遥操数采、后训练 + RL、端侧部署和机器人执行闭环及交付量产经验。

工作经历

上海傅利叶智能科技有限公司 · 具身算法工程师 2025.07 – 至今

VLA 后训练与实机闭环

- **π0.5 跨机型 Pick-and-Place 后训练** **〔北美行业巨头 Demo 交付〕** [痛点] 针对新机型数据稀缺与多本体动作空间异构、直接下游训练泛化差的问题，[方案] 采用六源数据混训并以 Mid-training 调整多机型数据配比，设计 Joint 与 relative EEF 统一动作表示，Post-training 微调 Action Expert；[成果] 大小两种人形平台完成桌面多物体抓取入框，搭建 S0–S3 四级真机评测体系（**15+ 任务，覆盖空间/视觉/组合/语义与跨本体泛化**），实测组合泛化（旧物体 + 新容器）**95%**、未见类别物体可抓取、更换场景仍能定位，**完美完成 Demo 交付**；[探索] Flow-based GRPO，结合任务完成、避障奖励与 BC 约束优化策略。
- **Handover 优化与 Progress Head** [痛点] 针对 handover 脏帧致模型犹豫顿挫、长程任务依赖人工判停、进度信号与动作耦合拖累主任务的问题，[方案] 基于关节状态识别无效动作并清洗脏帧、推理 chunk 下采样，并在 VLM 塔新增 Progress Head（detach 梯度隔离）输出进度与完成信号，[成果] 顿挫消除且保持 Regrasp 与跟随能力，提速约 **1.3×**；长程任务链路全任务成功率 **95%+**，递水/handover 耗时下降 **60%**，任务**位置任意泛化**。
- **工业螺钉装配与在线 RL** **〔芯片行业巨头 · 展会 Demo 交付〕** [痛点] 针对产线环境遮挡（冷凝水管挡台面）与孔位高精度对准、浮动基精度不够高等问题，[方案] 主导装配状态机与执行 Pipeline，融合 rule-based 和 model-based 技术路线，SIMPLE_EASYHEC + GroundedSAM2 自动手眼标定，集成 Grounding DINO 检测与运动规划；ResNet + MLP 示教 SFT 策略，基于 HIL-SERL 框架做 SAC 在线强化学习，以视觉奖励分类器判定任务成功，配合安全回退与电动螺丝刀时序控制，[成果] 标定误差稳定 **±1 cm / ±2°**，完美模拟**客户产线长时间 6 孔对准-插入-拧紧全闭环展会 demo**。
- **VLA 实机执行：**搭建可复用的策略推理与执行系统，解耦推理与实时控制，支持 Inference-time Inpainting RTC 动作衔接；集成多机型动作映射、IK、DDS 通信及数据录制回流，接入主线版本并支撑**多项目交付**。

模型量化与端侧推理部署

- **π0.5 推理加速：**面向 Jetson Orin / Thor 优化 TensorRT 与 FlashRT 双后端，结合混合精度量化、敏感算子精度回退、CUDA Graph 与 Prefix KV Cache 复用，模型推理整链路延迟分别优化至 **120 / 90 ms**，较 4090 端推理提速 **20%+**。
- **多模型推理加速：**基于 LoRA 与 Location Token 优化 Qwen3-VL 开放词汇定位，单框输出从 18–24 Token 缩短至 **5 Token**，Thor NVFP4 部署下单目标定位最高约 **10 Hz**；Kimodo Denoiser 在 Orin 上单步延迟降低约 **30%**，优化至 **20.3 ms**；运控 Policy 的 CPU / GPU 推理延迟分别降低约 **40% / 60%**。
- **量化产线与统一推理框架：**搭建 TRT / FlashRT 自动化量化与部署产线，覆盖 VLA、VLM、感知及运控 Policy 的模型接入、精度/延迟门禁、目标端构建和 Bundle 交付，配置快照与产物哈希实现可追溯、可复现；建设 C++ / Python 统一 Runner，抽象模型加载、Tensor / Spec、GPU 内存管理与异步执行接口，适配 ONNX Runtime、TensorRT、FlashRT、vllm.cpp 等后端，支持 ARM64 端侧部署。

机器人遥操作与数采

- **外骨骼遥操与力控数据采集：**参与同构/异构外骨骼及人机工学优化，开发关节标定、运动映射与 6/12 DoF 手部解算；基于 Dora 集成外骨骼、Manus、Vive、Quest / Vision Pro 等遥操设备，并在天机机械臂平台上扩展力信息采集及擦桌、钻孔等力控任务。

杭州柳叶刀机器人有限公司 · 机械臂算法实习生 2024.05 – 2024.08

- **机械臂算法：**参与手眼 / TCP 标定、双目定位、碰撞检测、运动与力控及系统测试；以第一发明人申请机械臂碰撞检测专利。

教育经历

密歇根大学安娜堡分校 · 机械工程硕士（机器人方向）· GPA 4.0/4.0 2023.09 - 2025.05

导师 Prof. Nima Fazeli（MMinTLab）· 研究方向：机械臂 manipulation

宁波诺丁汉大学 · 航空航天工程本科 · GPA 3.95/4.0 2019.07 - 2023.05

荣誉与专利

- **荣誉：**浙江省优秀毕业生、国家奖学金、浙江省奖学金。
- **专利：**《一种机械臂碰撞检测方法》· 公开号 CN118952202A · 第一发明人